

郑凯晟

Email: zhengkaisheng@link.cuhk.edu.hk
Tel: 18002502221



教育背景

香港中文大学, 人工智能理学硕士 & 科研助理	2025.09 - 2026.12
南方科技大学, 计算机科学与技术工学学士	2021.09 - 2025.07
• 优秀毕业论文、美国大学生数学建模竞赛 M 奖、国际基因工程机器大赛 (iGEM) 2023 银奖、iGEM 2024 金奖	

科研经历

基于图像 KV Cache 跨请求复用的 VLM 推理优化 (EMNLP Findings 2026) , 共一	2026.03 - 2026.05
项目描述: 改进位置无关的 KV Cache 复用算法, 解决在 VRAG, Agentic System, Video understanding 等存在大量相同图片跨请求输入的场景中, 因输入顺序不定导致 Prompt Cache 失效的问题。	
• 设计位置无关 KV Cache 复用框架, 通过独立上下文预计算并缓存多模态输入的 KV 向量, 动态恢复位置编码后拼接到当前上下文实现复用。	
• 引入部分 Token 重计算策略, 仅需重算 10% 的图片 Token 即在 MMLongBench 上达到完整 prefill 98% 的精度。	
• 基于 nanovllm 推理框架开发并集成 FlashInfer 稀疏注意力算子, 实现不同 context length 下平均 2.99x 的 TTFT 加速。	

实习经历

安克创新, 计算机视觉算法实习生	2025.04 - 2025.07
项目描述: MAST3R-SLAM 鱼眼相机与草坪场景优化。针对 MAST3R-SLAM 在草坪弱纹理、急转弯等场景下匹配丢失与重定位失败问题, 改进特征匹配模块并融合外部深度约束, 提升极端条件下的连续定位能力。	
• 定位原框架特征匹配模块在重复纹理和大幅度视角变化下的 failure case。	
• 调研并横向对比 SuperGlue, LoFTR 等多种图像匹配方法在草坪场景中的表现, 最终引入 SuperPoint+LightGlue 方案替换原生匹配模块, 增强极端视角与低纹理区域的匹配鲁棒性。	
• 融合 ZED 深度相机替代原单目深度估计, 利用外部真实尺度约束抑制轨迹漂移, 在无回环检测条件下显著缓解重定位失败问题。	

项目经历

UNet-Transformer 生物大模型的结构化剪枝与重训练	2025.12 - 2026.01
项目描述: 针对 BERT-Style 基因组大模型 (NTv3-650M) 部署成本高的问题, 设计混合架构的三阶段结构化剪枝与持续预训练 (CPT) 框架, 将参数量压缩至 15%, 精度保持在原模型的 91%。	
• 针对 UNet 中复杂的跨层依赖关系, 引入 DepGraph 算法自动处理跨层依赖并构建剪枝组。	
• 针对模型不同内部结构的特点采用不同的剪枝算法。UNet 结构采用基于梯度的 Taylor 剪枝, Transformer bottleneck 则采用基于 PPL sensitivity 的深度剪枝。	
• 设计数据处理和训练 pipeline, 在 2.5T Tokens 上进行再训练恢复模型表征能力, 在 500B 时收敛。在多物种的下游基因功能预测任务中, 压缩后的模型恢复了原模型 91.5% 的性能, 且较同规模从零训练的基线模型提升 1.55%。	

基于主动学习的自动驾驶场景下 3d 目标检测网络训练	2024.09 - 2024.12
项目描述: 自动驾驶场景下 3D 点云标注成本较高, 通过设计多样性采样主动学习策略, 来减少训练数据标注的需求的同时提高训练精度。	
• 设计基于 coresets 多样性采样的主动学习策略, 利用模型卷积特征图作为嵌入表示, 通过最远点采样在特征空间均匀选取高多样性样本, 提升数据利用效率。	
• 最终以 1/3 的训练数据与 1/5 的训练步数, 在 KITTI 数据集上达到与原 SECOND 论文一致的检测精度。	

专业技能

熟悉 Python 语言, PyTorch、Transformers、Datasets、PEFT 等常用深度学习库;
熟悉主流 LLM, VLM 架构; 熟悉 vLLM, SGLang 等推理框架; 熟悉 Triton。
了解 DeepSpeed、Megatron-LM 并行训练框架。熟悉 Linux 操作, Docker, k8s。